

线图提取优化方案

- 1.YOLO
- 2.匹配
- 3.OCR

线图提取主要分为两步：

- 线图标注：使用训练的YOLO模型对线图进行标注，识别线图上的器物，图注，序号等，以及坐标信息。结果如下图：



- 结果处理：使用脚本对线图坐标信息进行精确处理，对检测到的线图与相关文字信息进行匹配和裁剪。目前使用的代码如下，以生成一个命名完成的线图文件夹。

```
1  import os
2  import shutil
3  from PIL import Image
4  import numpy as np
5  from paddleocr import PaddleOCR
6  import re
7
8  # 读取坐标文档
9  def read_detections(txt_path):
10     detections = []
11     with open(txt_path, 'r') as file:
12         for line in file:
13             parts = line.strip().split(' ')
14             detections.append([int(parts[0])] + [float(part) for part in
15 parts[1:]])
16     return detections
17
18 # 创建保存裁剪图片的文件夹
19 def create_save_folder(path):
20     if os.path.exists(path):
21         shutil.rmtree(path)
22     os.makedirs(path)
23
24 # 清理文本，确保只包含合法的文件名字符
25 def clean_text(text):
26     # 移除非法字符
27     cleaned_text = re.sub(r'[\\"/:*?"<>|]', '', text)
28     # 移除空白字符
29     cleaned_text = cleaned_text.strip()
30     # 限制文本长度
31     max_length = 100 # 设定最大长度为100个字符
32     if len(cleaned_text) > max_length:
33         cleaned_text = cleaned_text[:max_length]
34     return cleaned_text
35
36 # 全局变量初始化
37 last_caption = "default_caption"
38 # 处理图片和坐标
39 def process_image(txt_folder, img_folder, save_folder):
40     global last_caption
41     ocr = PaddleOCR(use_angle_cls=True, lang="ch")
42     create_save_folder(save_folder)
43     for txt_file in os.listdir(txt_folder):
```

```

44         if txt_file.endswith('.txt'):
45             # 为每张图片重新初始化已使用的索引集合
46             used_indices = set()
47             txt_path = os.path.join(txt_folder, txt_file)
48             img_name = os.path.splitext(txt_file)[0] + '.jpg'
49             img_path = os.path.join(img_folder, img_name)
50
51             if os.path.exists(img_path):
52                 detections = read_detections(txt_path)
53                 img = Image.open(img_path)
54                 width, height = img.size
55
56                 overall_found = False
57
58                 for det in detections:
59                     if det[0] == 4:
60                         overall_found = True
61                         overall_bounds = [det[1:5], width, height]
62                         elements_within_frame = filter_elements(detection
63 s, overall_bounds, width, height)
64
65                         caption_text = ""
66                         found_caption = False
67
68                         for element in elements_within_frame:
69                             if element[0] == 2:
70                                 caption_text = extract_caption_text(element
71 nt, img, ocr, width, height)
72                                 if caption_text:
73                                     last_caption = caption_text # 更新最
74 后一个成功的图注
75                                     found_caption = True
76                                     break
77
78                                 if not found_caption and last_caption:
79                                     # 如果没有找到新的图注, 并且有先前的图注, 生成新的图
80 注
81                                     caption_text = increment_chinese_number(last_
82 caption)
83
84                                     for element in elements_within_frame:
85                                         if element[0] != 2: # 非图注的元素处理
86                                             process_element(element, img, ocr, save_f
87 older, width, height, caption_text, elements_within_frame, used_indices)
88
89                                     if not overall_found: # 没有找到整体框, 处理器物 and 图注

```

```

85         process_items_without_overall_box(detections, img, ocr,
86         r, save_folder, width, height)
87
88 # 处理没有整体框的情况
89 def process_items_without_overall_box(detections, img, ocr, save_folder,
90 width, height):
91     items = [det for det in detections if det[0] == 0]
92     captions = [det for det in detections if det[0] == 2]
93     indices = [det for det in detections if det[0] == 1]
94
95     for item in items:
96         caption_text = find_closest_caption(item, captions, width, height,
97         img, ocr)
98         index_text, _ = find_closest_index_box(item, indices, width, height,
99         img, ocr)
100         if caption_text and index_text:
101             filename = os.path.join(save_folder, f"{caption_text}_{index_
102             text}.jpg")
103             img_roi = crop_to_box(item, img, width, height)
104             img_roi.save(filename)
105
106 # 寻找最近的图注
107 def find_closest_caption(item, captions, width, height, img, ocr):
108     x_center, y_center = item[1], item[2]
109     min_distance = float('inf')
110     closest_caption = None
111
112     for caption in captions:
113         cap_x_center, cap_y_center = caption[1], caption[2]
114         distance = np.sqrt((x_center - cap_x_center) ** 2 + (y_center - c
115         ap_y_center) ** 2)
116         if distance < min_distance:
117             min_distance = distance
118             closest_caption = caption
119
120     if closest_caption:
121         img_roi = crop_to_box(closest_caption, img, width, height)
122         ocr_result = ocr.ocr(np.array(img_roi), cls=True)
123         if ocr_result and ocr_result[0]:
124             return clean_text(ocr_result[0][0][1][0])
125     return "default"

```

中文数字映射

```

126 chinese_to_arabic = {
127     '0': 0, '一': 1, '二': 2, '三': 3, '四': 4,
128     '五': 5, '六': 6, '七': 7, '八': 8, '九': 9,

```

```

126     '十': 10
127 }
128
129 def chinese_to_arabic_num(chinese_str):
130     """将连续的中文数字（如“二一八”）直接转换为阿拉伯数字"""
131     num_map = {'0': 0, '一': 1, '二': 2, '三': 3, '四': 4, '五': 5,
132               '六': 6, '七': 7, '八': 8, '九': 9, '十': 10}
133     result = 0
134     for char in chinese_str:
135         value = num_map.get(char)
136         if value is None:
137             continue # Skip invalid characters
138         result = result * 10 + value
139     return result
140
141
142
143 def arabic_to_chinese(num):
144     """将阿拉伯数字转换为不带单位的中文数字，例如218转换为“二一八"""
145     num_str = str(num)
146     num_map = {0: '0', 1: '一', 2: '二', 3: '三', 4: '四', 5: '五',
147               6: '六', 7: '七', 8: '八', 9: '九'}
148     result = ''.join(num_map[int(digit)] for digit in num_str)
149     return result
150
151
152 def increment_chinese_number(caption):
153     """自动递增图注中的末尾连续中文数字"""
154     # 匹配连续中文数字部分
155     pattern = re.compile(r'[一二三四五六七八九0]+')
156     match = pattern.search(caption)
157     if match:
158         chinese_num = match.group(0)
159         arabic_num = chinese_to_arabic_num(chinese_num)
160         incremented_num = arabic_num + 1
161         new_chinese_num = arabic_to_chinese(incremented_num)
162         return caption.replace(chinese_num, new_chinese_num)
163     return caption
164
165
166
167
168
169
170
171
172

```

```

173 def intersection_over_union(det, overall_bounds, width, height):
174     # 解析整体框的边界
175     x_center, y_center, w, h = overall_bounds[0]
176     box_x_min = (x_center - w / 2) * width
177     box_y_min = (y_center - h / 2) * height
178     box_x_max = (x_center + w / 2) * width
179     box_y_max = (y_center + h / 2) * height
180
181     # 解析元素的边界
182     ele_x_center, ele_y_center, ele_w, ele_h = det[1:5]
183     ele_x_min = (ele_x_center - ele_w / 2) * width
184     ele_y_min = (ele_y_center - ele_h / 2) * height
185     ele_x_max = (ele_x_center + ele_w / 2) * width
186     ele_y_max = (ele_y_center + ele_h / 2) * height
187
188     # 计算交集
189     inter_x_min = max(box_x_min, ele_x_min)
190     inter_y_min = max(box_y_min, ele_y_min)
191     inter_x_max = min(box_x_max, ele_x_max)
192     inter_y_max = min(box_y_max, ele_y_max)
193
194     if inter_x_min < inter_x_max and inter_y_min < inter_y_max:
195         # 交集区域
196         inter_area = (inter_x_max - inter_x_min) * (inter_y_max - inter_y
197         _min)
198         # 元素的区域
199         ele_area = (ele_x_max - ele_x_min) * (ele_y_max - ele_y_min)
200         # 计算交集与元素面积的比例
201         iou = inter_area / ele_area
202         return iou >= 0.5
203     return False
204
205 def filter_elements(detections, overall_bounds, width, height):
206     filtered_elements = []
207     for det in detections:
208         if intersection_over_union(det, overall_bounds, width, height):
209             filtered_elements.append(det)
210     return filtered_elements
211
212
213 def extract_caption_text(det, img, ocr, width, height):
214     img_roi = crop_to_box(det, img, width, height)
215     ocr_result = ocr.ocr(np.array(img_roi), cls=True)
216     if ocr_result:
217         full_text = ocr_result[0][0][1][0]
218         match = re.match(r"^[^\d]*", full_text)

```

```

219         if match:
220             return clean_text(match.group())
221     return ""
222
223 # Global counter for default indexing
224 default_index_counter = 0
225 def increment_default_index():
226     global default_index_counter
227     default_index_counter += 1
228     return f"default_{default_index_counter}"
229
230 def process_element(det, img, ocr, save_folder, width, height, caption_text, all_detections, used_indices):
231     img_roi = crop_to_box(det, img, width, height)
232     filename = None
233
234     if det[0] == 3:
235         filename = os.path.join(save_folder, f"{caption_text}.jpg")
236     elif det[0] == 0:
237         idx_text, closest_index_box = find_closest_index_box(det, all_detections, width, height, img, ocr)
238         if closest_index_box and idx_text not in used_indices:
239             used_indices.add(idx_text) # 标记此索引为已使用
240             filename = os.path.join(save_folder, f"{caption_text}, {idx_text}.jpg")
241
242         # 裁剪并保存序号框
243         index_box_img_roi = crop_to_box(closest_index_box, img, width, height, enlarge=True)
244         index_box_img_roi = enlarge_image(index_box_img_roi, 5) # 放大序号框
245
246     else:
247         idx_text = increment_default_index() # 使用自动递增的默认索引
248         filename = os.path.join(save_folder, f"{caption_text}, {idx_text}.jpg")
249
250     if filename:
251         img_roi.save(filename)
252
253
254
255 def find_closest_index_box(det, all_detections, width, height, img, ocr):
256     x_center, y_center, w, h = det[1], det[2], det[3], det[4]
257     best_coverage = 0
258     closest_index_box = None

```

```

259     idx_text = increment_default_index() # Start with a unique default i
260     ndex each time
261
262     for idx_box in all_detections:
263         if idx_box[0] == 1:
264             idx_x_center, idx_y_center, idx_w, idx_h = idx_box[1], idx_bo
265             x[2], idx_box[3], idx_box[4]
266             inter_left = max(x_center - w / 2, idx_x_center - idx_w / 2)
267             inter_top = max(y_center - h / 2, idx_y_center - idx_h / 2)
268             inter_right = min(x_center + w / 2, idx_x_center + idx_w / 2)
269             inter_bottom = min(y_center + h / 2, idx_y_center + idx_h /
270             2)
271             if inter_right > inter_left and inter_bottom > inter_top:
272                 inter_area = (inter_right - inter_left) * (inter_bottom
273                 - inter_top)
274                 idx_area = idx_w * idx_h
275                 coverage = inter_area / idx_area
276                 if coverage > best_coverage and coverage > 0.5: # Check
277                     against a threshold
278                     best_coverage = coverage
279                     closest_index_box = idx_box
280
281             if closest_index_box:
282                 idx_x_center, idx_y_center, idx_w, idx_h = closest_index_box[1],
283                 closest_index_box[2], closest_index_box[3], closest_index_box[4]
284                 idx_img_roi = crop_to_box(closest_index_box, img, width, height,
285                 enlarge=True)
286                 idx_img_roi = enlarge_image(idx_img_roi, 5) # 放大序号框
287                 ocr_result = ocr.ocr(np.array(idx_img_roi), cls=True)
288                 if ocr_result and ocr_result[0]:
289                     idx_text = clean_text(ocr_result[0][0][1][0])
290
291             return idx_text, closest_index_box if closest_index_box else False
292
293 # 放大图片
294 def enlarge_image(image, scale_factor):
295     # 获取原图尺寸
296     original_size = image.size
297     # 计算放大后的尺寸
298     new_size = (int(original_size[0] * scale_factor), int(original_size
299     [1] * scale_factor))
300     # 放大图片
301     enlarged_image = image.resize(new_size, Image.LANCZOS) # 使用 LANCZO
302     S 替代 ANTIALIAS
303     return enlarged_image

```



```

298 def crop_to_box(box, img, width, height, enlarge=False):
299     x_center, y_center, w, h = box[1:5]
300     x_min = max(0, int((x_center - w / 2) * width))
301     y_min = max(0, int((y_center - h / 2) * height))
302     x_max = min(width, int((x_center + w / 2) * width))
303     y_max = min(height, int((y_center + h / 2) * height))
304     img_crop = img.crop((x_min, y_min, x_max, y_max))
305
306     if enlarge:
307         img_crop = img_crop.resize((img_crop.width * 5, img_crop.height
308 * 5), Image.LANCZOS)
309
310     return img_crop
311 # 示例调用
312 txt_folder = r'E:\庙前\labels'

```

目前出现了裁剪命名的线图文件夹命名率低的问题，主要原因可能三个：

- yolo: yolo对新的考古报告线图没有很好的进行识别
- 匹配：代码逻辑没有正确的将线图和图注做匹配
- ocr: paddleocr对文字没有很好的识别


以《文家山》为例，观察其中img以解决yolo识别问题，观察裁剪文件夹以解决命名问题。

 [文家山labels+imgs.rar](#)

 [裁剪图像文件夹-文家山.rar](#)

1.YOLO

观察《文家山》发现，线图都被很好识别到，但是出现了对大量玉管命名失败的现象：



珠 85 件。根据形状可分两型。

A 型 78 颗。腰鼓形，器物大小相差较悬殊，高矮胖瘦也多有不同，长 0.4~2.5、直径 0.3~1.5 厘米。大部分出自 M1。


器物有 M1 : 44、M1 : 48、M1 : 49、M1 : 52、M1 : 53、M1 : 54、M1 : 57、M1 : 59、M1 : 61、M1 : 63、M1 : 64、M1 : 65、M1 : 66、M1 : 67、M1 : 68、M1 : 69、M1 : 70、M1 : 71、M1 : 72、M1 : 73、M1 : 74、M1 : 75、M1 : 77、M1 : 78、M1 : 79、M1 : 80、M1 : 81、M1 : 82、M1 : 83、M1 : 84、M1 : 85、M1 : 86、M1 : 87、M1 : 92、M1 : 93、M1 : 95、M1 : 96、M1 : 99、M1 : 100、M1 : 101、M1 : 102、M1 : 104、M1 : 105、M1 : 106、M2 : 12、M3 : 6、M3 : 10、M4 : 2、M4 : 5、M4 : 6、M9 : 2、M9 : 3、M9 : 5、M9 : 7、M9 : 9、M12 : 2、M13 : 1、M13 : 2、M13 : 4、M13 : 5、M13 : 7、

建议采取的办法是：

- 优化数据集：检查是否有漏标的现象，补充一些如玉管等常见器物线图的训练，测试效果
- 换用更高版本的模型：v10

2. 匹配

将《文家山》考古报告其中标注正确，序号识别不好的一页143（如下图）：



厘米。(图 3-3B; 彩版二六, 5)

M2:14, 陶尊。泥质黑皮陶。直口略卷, 圆唇, 肩部弧折, 圈足外撇。口径 10.7、高 15.5 厘米。(图 3-3B; 彩版二七, 1)

M2:15, 陶豆。泥质黑皮陶。直口略卷, 折腹, 浅圈底。喇叭形豆把上部饰两道凹弦纹, 弦纹内戳有扁圆孔。口径 17.2、高 10.8 厘米。(图 3-3B; 彩版二七, 2)

M2:16, 陶鼎。夹砂红陶。无法修复。


M3

位于 T0302 南部, 开口于②层下, 打破③层。南半部被一晚期扰坑打破, 扰坑内出土 1 枚玉管和 1 件石钺。长方形竖穴土坑, 方向 183°。墓坑残长 150、宽 80、残深 6 厘米。未见葬具及人骨遗迹。随葬品共 11 件, 分别为石钺 6 件、玉珠 2 颗和陶鼎、豆、宽把杯各 1 件。(图 3-4A; 彩版二八~三〇)

M3:1, 石钺。灰色泥岩, 疏松, 残损严重。残长 13 厘米。(图 3-4C; 彩版二九, 1)

M3:2, 石钺。紫灰色粉砂质泥岩。制作较粗糙, 碎裂成多块。舌形刃, 背部圆鼓, 单面钻孔, 穿孔较大。长 15、刃宽 9.5、厚 0.9、孔径 3.5 厘米。(图 3-4C; 彩版二九, 2)

按yolo所给的坐标进行了裁剪, 得到序号图片 M2:3

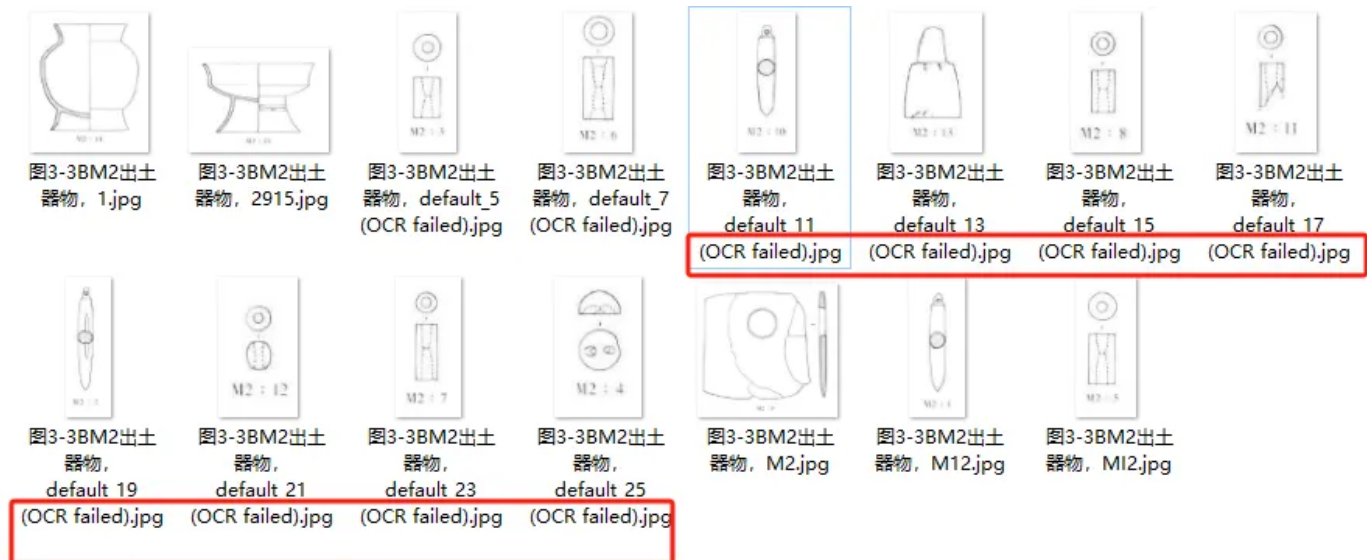


写了一段使用paddleocr识别图片的代码, 该图片可以识别出序号

但是在匹配中却出现了默认命名的情况



查看其识别错误的原因, 均是由ocr未识别到序号导致的:



建议采取的办法是：

- 可能是在代码的逻辑上出现了错误

3.OCR

在识别图注序号时，发现了图注基本都能被正确识别命名，但是在序号上会发现很多错误，首先解决序号识别错误的问题

建议采取的办法是：

- 可能是图像质量影响到了识别，在ocr代码之前加入更多图像预处理的操作：图像增强，二值化等
- 换用其他ocr模型